

```
In [3]: import warnings
warnings.filterwarnings("ignore")
import pandas as pd
import sqlite3
import csv
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
from wordcloud import WordCloud
import re
import os
from sqlalchemy import create_engine # database connection
import datetime as dt
from nltk.corpus import stopwords
from nltk.tokenize import word_tokenize
from nltk.stem.snowball import SnowballStemmer
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.multiclass import OneVsRestClassifier
from sklearn.linear_model import SGDClassifier
from sklearn import metrics
from sklearn.metrics import f1_score,precision_score,recall_score
from sklearn import svm
from sklearn.linear_model import LogisticRegression
from sklearn.naive_bayes import GaussianNB
from datetime import datetime
import pickle
```

## 5. Assignments

1. Use bag of words upto 4 grams and compute the micro f1 score with Logistic regression(OvR)
2. Perform hyperparam tuning on alpha (or lambda) for Logistic regression to improve the performance using GridSearch
3. Try OneVsRestClassifier with Linear-SVM (SGDClassifier with loss-hinge)

Modeling with less data points (0.1M data points) and more weight to title and 500 tags only.

```
In [1]: def tags_to_choose(n):
        t = multilabel_y.sum(axis=0).tolist()[0]
        sorted_tags_i = sorted(range(len(t)), key=lambda i: t[i], reverse=True)
        multilabel_yn=multilabel_y[:,sorted_tags_i[:n]]
        return multilabel_yn

        def questions_explained_fn(n):
            multilabel_yn = tags_to_choose(n)
            x= multilabel_yn.sum(axis=1)
            return (np.count_nonzero(x==0))

In [ ]: #Taking only 0.1 Million entries to a dataframe due to computational constrain.
con = sqlite3.connect('Titlemoreweight.db')
processed = pd.read_sql_query("""SELECT * FROM QuestionsProcessed""", con)

In [5]: processed.head()
```

	question	code	tags	words_pre	words_post	is_code
0	dynam datagrid bind silverlight dynam datagrid...	[MyClass myInstance = new MyClass();\ndataGri...	c# silverlight data-binding	904	252	1
1	dynam datagrid bind silverlight dynam datagrid...	[MyClass myInstance = new MyClass();\ndataGri...	c# silverlight data-binding columns	904	252	1
2	java.lang.noclassdeffoundererror javax servlet j...	[&lt;%@taglib prefix="c" uri="http://java.sun...	jsp jstl	745	463	1
3	java.sql.sqlexcept microsoft odbc driver manag...	[try {\n Class.forName("sun.jdbc.odbc.Jdbc...	java jdbc	1056	249	1
4	better way updat feed fb php sdk better way up...	[\$data = array("message" =&gt; "Hello World!"...	facebook api facebook-php-sdk	607	233	1

```
In [ ]: preprocessed_data=pd.read_sql_query("""SELECT question, Tags FROM QuestionsProcessed LIMIT 100000""", con)
preprocessed_data.head()

In [7]: print("number of data points in sample :", preprocessed_data.shape[0])
print("number of dimensions :", preprocessed_data.shape[1])

        number of data points in sample : 100000
        number of dimensions : 2
```


### Converting string Tags to multilable output variables

```
In [8]: vectorizer = CountVectorizer(tokenizer = lambda x: x.split(), binary='true')
multilabel_y = vectorizer.fit_transform(preprocessed_data['tags'])
```

### Selecting 500 Tags

```
In [9]: questions_explained = []
total_tags=multilabel_y.shape[1]
total_qs=preprocessed_data.shape[0]
for i in range(500, total_tags, 100):
    questions_explained.append(np.round(((total_qs-questions_explained_fn(i))/total_qs)*100,3))
```

```
In [10]: fig, ax = plt.subplots()
ax.plot(questions_explained)
xlabel = list(500+np.array(range(-50,450,50))*50)
ax.set_xticklabels(xlabel)
plt.xlabel("Number of tags")
plt.ylabel("Number Questions coverd partially")
plt.grid()
plt.show()
# you can choose any number of tags based on your computing power, minimun is 500(it covers 90% of the tags)
print("with ",5500,"tags we are covering ",questions_explained[50],"% of questions")
print("with ",500,"tags we are covering ",questions_explained[0],"% of questions")
```



with 5500 tags we are covering 99.481 % of questions  
with 500 tags we are covering 92.5 % of questions

```
In [11]: # we will be taking 500 tags
multilabel_yx = tags_to_choose(500)
print("number of questions that are not covered :", questions_explained_fn(500),"out of ", total_qs)
```

number of questions that are not covered : 7500 out of 100000

```
In [12]: # Train Test Split
train_datsize=80000
x_train=preprocessed_data.head(train_datsize)
x_test=preprocessed_data.tail(preprocessed_data.shape[0] - 80000)

y_train = multilabel_yx[0:train_datsize,:]
y_test = multilabel_yx[train_datsize:preprocessed_data.shape[0],:]
```

```
In [13]: print("Number of data points in train data :", y_train.shape)
print("Number of data points in test data :", y_test.shape)
```

Number of data points in train data : (80000, 500)  
Number of data points in test data : (20000, 500)

# 1. Use bag of words upto 4 grams and compute the micro f1 score with Logistic regression(OvR)

## Featurizing data with BOW vectorizer

NOTE: Limiting Maximum features to 100k because of coumputational strain

```
In [15]: # Bag OF Word of n_gram_range=(1,4)
start = datetime.now()
vectorizer = CountVectorizer(tokenizer = lambda x: x.split(), ngram_range=(1,4),max_features=100000)
x_train_multilabel = vectorizer.fit_transform(x_train['question'])
x_test_multilabel = vectorizer.transform(x_test['question'])
print("Time taken to run this cell :", datetime.now() - start)
```

Time taken to run this cell : 0:01:04.732305

```
In [16]: print("Dimensions of train data X:",x_train_multilabel.shape, "Y :",y_train.shape)
print("Dimensions of test data X:",x_test_multilabel.shape,"Y:",y_test.shape)
```

Dimensions of train data X: (80000, 100000) Y : (80000, 500)  
Dimensions of test data X: (20000, 100000) Y: (20000, 500)

Note : Taking only 100000 datapoint and 100k maximum feature because of computational constrain

```
In [26]: start = datetime.now()
        classifier_2 = OneVsRestClassifier(LogisticRegression(penalty='l1', n_jobs=-1),)
        classifier_2.fit(x_train_multilabel, y_train)
        predictions_2 = classifier_2.predict(x_test_multilabel)
        print("Accuracy :",metrics.accuracy_score(y_test, predictions_2))
        print("Hamming loss ",metrics.hamming_loss(y_test,predictions_2))

        precision = precision_score(y_test, predictions_2, average='micro')
        recall = recall_score(y_test, predictions_2, average='micro')
        f1 = f1_score(y_test, predictions_2, average='micro')

        print("Micro-average quality numbers")
        print("Precision: {:.4f}, Recall: {:.4f}, F1-measure: {:.4f}".format(precision, recall, f1))

        precision = precision_score(y_test, predictions_2, average='macro')
        recall = recall_score(y_test, predictions_2, average='macro')
        f1 = f1_score(y_test, predictions_2, average='macro')

        print("Macro-average quality numbers")
        print("Precision: {:.4f}, Recall: {:.4f}, F1-measure: {:.4f}".format(precision, recall, f1))

        print (metrics.classification_report(y_test, predictions_2))
        print("Time taken to run this cell :", datetime.now() - start)
```

Accuracy : 0.17445

Hamming loss 0.003358

Micro-average quality numbers

Precision: 0.5830, Recall: 0.3649, F1-measure: 0.4489

Macro-average quality numbers

Precision: 0.4208, Recall: 0.2851, F1-measure: 0.3288

	precision	recall	f1-score	support
0	0.69	0.39	0.50	820
1	0.53	0.32	0.40	1931
2	0.37	0.18	0.24	544
3	0.51	0.21	0.29	222
4	0.70	0.51	0.59	1311
5	0.75	0.51	0.61	1014
6	0.66	0.44	0.53	1374
7	0.73	0.59	0.65	702
8	0.90	0.63	0.74	1424
9	0.75	0.64	0.69	1037
10	0.72	0.57	0.64	797
11	0.55	0.38	0.45	156
12	0.57	0.36	0.44	36
13	0.67	0.41	0.51	610
14	0.41	0.24	0.30	405
15	0.61	0.24	0.34	144
16	0.48	0.25	0.33	425
17	0.58	0.32	0.41	485
18	0.73	0.65	0.69	269
19	0.85	0.61	0.71	518
20	0.49	0.29	0.36	529
21	0.82	0.57	0.68	294
22	0.80	0.41	0.54	520
23	0.45	0.28	0.35	246
24	0.54	0.37	0.44	312
25	0.46	0.33	0.38	314
26	0.56	0.30	0.39	190
27	0.31	0.12	0.17	342
28	0.36	0.26	0.30	96
29	0.29	0.16	0.20	32
30	0.64	0.47	0.54	747
31	0.45	0.36	0.40	14
32	0.62	0.61	0.62	166
33	0.56	0.35	0.43	171
34	0.54	0.31	0.39	256
35	0.79	0.55	0.65	199
36	0.15	0.08	0.11	60
37	0.26	0.19	0.22	203
38	0.68	0.49	0.57	201
39	0.40	0.31	0.35	208
40	0.25	0.15	0.19	13
41	0.35	0.16	0.22	154
42	0.34	0.30	0.32	69
43	0.29	0.20	0.24	426
44	0.44	0.27	0.34	77
45	0.47	0.29	0.36	223
46	0.51	0.33	0.40	144
47	0.69	0.49	0.57	245
48	0.42	0.20	0.27	91
49	0.59	0.41	0.48	157
50	0.90	0.67	0.77	132
51	0.84	0.66	0.74	41
52	0.56	0.42	0.48	124
53	0.23	0.26	0.24	96
54	0.18	0.12	0.15	128
55	0.50	0.24	0.32	46
56	0.66	0.64	0.65	151
57	0.08	0.01	0.02	80
58	0.32	0.17	0.22	65
59	0.37	0.16	0.23	182
60	0.90	0.69	0.78	148
61	0.36	0.14	0.20	196
62	0.27	0.21	0.24	58
63	0.86	0.28	0.42	43
64	0.61	0.34	0.44	197
65	0.65	0.43	0.51	82
66	0.69	0.54	0.61	50
67	0.59	0.54	0.56	105
68	0.16	0.05	0.08	98
69	0.21	0.07	0.10	238
70	0.25	0.09	0.13	35
71	0.51	0.50	0.50	54
72	0.00	0.00	0.00	25
73	0.29	0.24	0.26	29
74	0.20	0.10	0.14	29
75	0.26	0.23	0.24	40
76	0.77	0.55	0.64	105
77	0.58	0.50	0.54	28
78	0.18	0.09	0.12	202
79	0.54	0.41	0.46	37
80	0.50	0.33	0.40	15
81	0.47	0.27	0.34	52
82	0.38	0.28	0.32	50
83	0.21	0.05	0.09	56
84	0.73	0.59	0.65	54
85	0.58	0.62	0.60	34
86	0.23	0.20	0.21	30
87	0.56	0.34	0.43	29
88	0.71	0.83	0.77	24
89	0.83	0.79	0.81	117
90	0.11	0.06	0.08	66
91	0.39	0.25	0.30	68
92	0.67	0.30	0.41	67
93	0.53	0.36	0.43	28
94	0.42	0.29	0.34	17
95	0.74	0.49	0.59	51
96	0.57	0.43	0.49	53
97	0.08	0.02	0.03	61
98	0.08	0.03	0.04	79

Assignment Stackoverflow tag predictor				
99	0.47	0.44	0.46	18
100	0.50	0.09	0.15	11
101	0.62	0.58	0.60	207
102	0.00	0.00	0.00	6
103	0.25	0.03	0.06	30
104	0.29	0.09	0.14	54
105	0.70	0.41	0.52	39
106	0.29	0.13	0.18	70
107	0.40	0.14	0.21	14
108	0.58	0.17	0.26	66
109	0.53	0.34	0.41	50
110	0.56	0.26	0.36	87
111	0.40	0.43	0.42	51
112	0.86	0.06	0.12	291
113	0.97	0.76	0.85	49
114	0.32	0.10	0.15	110
115	0.17	0.04	0.06	28
116	0.00	0.00	0.00	5
117	0.25	0.09	0.13	56
118	0.74	0.45	0.56	125
119	0.70	0.43	0.54	44
120	0.75	0.36	0.48	42
121	0.38	0.20	0.26	55
122	0.67	0.43	0.52	68
123	0.16	0.10	0.12	82
124	0.00	0.00	0.00	0
125	0.71	0.71	0.71	7
126	0.12	0.06	0.08	18
127	0.40	0.13	0.20	31
128	0.75	0.46	0.57	13
129	0.64	0.54	0.59	50
130	0.19	0.10	0.13	91
131	0.64	0.60	0.62	35
132	0.21	0.12	0.15	26
133	0.25	0.06	0.10	32
134	0.61	0.40	0.48	35
135	0.76	0.68	0.71	37
136	0.00	0.00	0.00	55
137	0.24	0.39	0.30	41
138	0.38	0.40	0.39	15
139	0.28	0.14	0.19	99
140	0.87	0.70	0.77	86
141	0.45	0.25	0.32	53
142	0.75	0.08	0.15	36
143	0.52	0.52	0.52	66
144	0.53	0.47	0.50	64
145	0.27	0.12	0.17	25
146	0.15	0.10	0.12	125
147	0.24	0.27	0.25	15
148	0.64	0.52	0.57	48
149	0.34	0.26	0.30	65
150	0.00	0.00	0.00	11
151	0.33	0.33	0.33	15
152	0.21	0.13	0.16	52
153	0.44	0.39	0.41	18
154	0.43	0.19	0.26	16
155	0.27	0.20	0.23	20
156	0.47	0.22	0.30	121
157	0.51	0.31	0.38	107
158	0.00	0.00	0.00	15
159	0.67	0.50	0.57	105
160	0.47	0.39	0.43	69
161	0.54	0.36	0.43	56
162	0.25	0.09	0.13	47
163	0.04	0.01	0.01	121
164	0.39	0.29	0.33	41
165	0.00	0.00	0.00	229
166	0.71	0.30	0.42	98
167	0.39	0.21	0.27	33
168	0.53	0.18	0.27	44
169	0.70	0.47	0.56	45
170	0.84	0.41	0.55	51
171	0.00	0.00	0.00	18
172	0.49	0.46	0.47	48
173	0.33	0.42	0.37	12
174	0.29	0.16	0.21	62
175	0.72	0.52	0.61	44
176	0.92	0.77	0.84	30
177	0.48	0.43	0.46	30
178	0.00	0.00	0.00	0
179	1.00	1.00	1.00	1
180	0.52	0.30	0.38	40
181	0.17	0.07	0.10	44
182	0.50	0.50	0.50	2
183	0.53	0.37	0.44	75
184	0.25	0.25	0.25	4
185	0.50	0.23	0.32	64
186	0.23	0.25	0.24	12
187	0.95	0.64	0.76	55
188	0.78	0.66	0.71	64
189	0.41	0.15	0.22	96
190	0.12	0.05	0.07	22
191	0.81	0.17	0.28	76
192	0.68	0.42	0.52	45
193	0.86	0.43	0.57	14
194	0.55	0.46	0.50	50
195	0.82	0.45	0.58	20
196	0.81	0.63	0.71	35
197	0.50	0.33	0.40	94
198	0.00	0.00	0.00	14
199	0.12	0.04	0.06	25
200	0.50	0.17	0.25	54
201	0.25	0.09	0.13	22
202	0.30	0.26	0.28	43
203	0.14	0.02	0.04	43
204	0.98	0.65	0.78	62
205	0.00	0.00	0.00	3
206	0.14	0.07	0.09	43

207	0.33	0.14	0.20	7
208	0.20	0.12	0.15	8
209	0.56	0.12	0.20	42
210	0.22	0.40	0.29	10
211	0.35	0.20	0.25	40
212	0.73	0.48	0.58	23
213	0.00	0.00	0.00	6
214	0.63	0.47	0.54	47
215	0.38	0.13	0.19	62
216	0.62	0.42	0.50	77
217	0.18	0.09	0.12	22
218	0.33	0.33	0.33	3
219	0.06	0.04	0.05	28
220	0.67	0.07	0.13	81
221	0.24	0.13	0.17	31
222	0.17	0.06	0.09	34
223	0.96	0.45	0.61	60
224	0.33	0.30	0.32	10
225	0.75	0.60	0.67	10
226	0.75	0.76	0.76	92
227	0.89	0.62	0.73	13
228	0.40	0.15	0.22	13
229	0.87	0.77	0.81	43
230	0.29	0.17	0.21	35
231	0.00	0.00	0.00	4
232	0.25	0.10	0.14	20
233	0.48	0.32	0.38	145
234	0.84	0.56	0.67	55
235	0.00	0.00	0.00	2
236	0.27	0.08	0.12	37
237	0.69	0.42	0.52	90
238	0.50	0.19	0.27	58
239	0.50	0.25	0.33	20
240	0.89	0.69	0.78	61
241	0.78	0.74	0.76	42
242	0.56	0.63	0.59	30
243	0.80	0.53	0.64	66
244	0.56	0.24	0.33	42
245	0.10	0.06	0.08	31
246	1.00	0.50	0.67	6
247	0.25	0.17	0.20	18
248	0.83	0.57	0.67	51
249	0.57	0.47	0.52	17
250	0.62	0.59	0.60	22
251	0.76	0.42	0.54	52
252	0.62	0.17	0.27	29
253	0.11	0.07	0.09	28
254	0.00	0.00	0.00	10
255	0.20	0.20	0.20	5
256	0.25	0.33	0.29	3
257	0.64	0.34	0.44	41
258	0.23	0.10	0.14	30
259	1.00	0.67	0.80	3
260	0.00	0.00	0.00	38
261	0.00	0.00	0.00	1
262	0.46	0.32	0.37	19
263	0.00	0.00	0.00	14
264	0.07	0.05	0.06	37
265	0.11	0.11	0.11	9
266	0.20	0.24	0.22	45
267	0.64	0.55	0.59	33
268	0.81	0.81	0.81	16
269	0.47	0.46	0.46	35
270	0.60	0.27	0.37	11
271	0.00	0.00	0.00	30
272	0.27	0.38	0.32	8
273	0.12	0.14	0.13	21
274	0.46	0.31	0.37	123
275	0.38	0.25	0.30	67
276	0.89	0.80	0.84	20
277	0.00	0.00	0.00	14
278	0.33	0.16	0.21	19
279	0.73	0.67	0.70	12
280	0.00	0.00	0.00	15
281	0.92	0.65	0.76	17
282	0.94	0.71	0.81	41
283	0.64	0.47	0.54	15
284	0.51	0.34	0.41	74
285	0.38	0.13	0.20	38
286	0.13	0.12	0.13	16
287	0.29	0.07	0.11	30
288	0.90	0.64	0.75	28
289	0.00	0.00	0.00	21
290	0.80	0.59	0.68	41
291	0.10	0.08	0.09	12
292	0.39	0.29	0.33	24
293	0.47	0.35	0.40	20
294	0.21	0.22	0.21	23
295	0.00	0.00	0.00	29
296	0.25	0.11	0.15	28
297	0.36	0.29	0.32	42
298	0.19	0.06	0.09	53
299	0.00	0.00	0.00	36
300	0.21	0.12	0.15	41
301	0.53	0.46	0.49	37
302	0.88	0.58	0.70	26
303	0.20	0.09	0.13	11
304	0.33	0.23	0.27	31
305	0.33	0.29	0.31	17
306	0.40	0.22	0.29	9
307	0.50	0.33	0.40	6
308	0.00	0.00	0.00	34
309	0.61	0.40	0.48	43
310	0.06	0.03	0.04	30
311	0.33	0.14	0.20	50
312	0.20	0.04	0.07	24
313	0.38	0.14	0.21	42
314	0.42	0.23	0.29	22

315	0.00	0.00	0.00	58
316	0.50	0.10	0.17	10
317	0.38	0.26	0.31	57
318	0.57	0.40	0.47	10
319	0.17	0.09	0.12	11
320	0.14	0.18	0.16	11
321	0.25	0.12	0.17	8
322	0.56	0.41	0.47	22
323	0.79	0.79	0.79	28
324	0.63	0.58	0.60	50
325	0.29	0.11	0.16	18
326	0.18	0.09	0.12	33
327	0.16	0.18	0.17	17
328	0.36	0.17	0.23	29
329	0.33	0.14	0.20	7
330	0.42	0.50	0.45	10
331	0.19	0.20	0.19	25
332	1.00	1.00	1.00	2
333	0.71	0.45	0.56	11
334	0.00	0.00	0.00	24
335	0.33	0.20	0.25	5
336	0.17	0.03	0.05	33
337	0.45	0.17	0.24	30
338	0.91	0.71	0.80	42
339	0.22	0.08	0.11	26
340	0.48	0.36	0.41	36
341	1.00	0.54	0.70	13
342	0.60	0.55	0.57	11
343	0.43	0.30	0.35	10
344	0.14	0.05	0.07	21
345	0.00	0.00	0.00	0
346	0.00	0.00	0.00	6
347	0.00	0.00	0.00	12
348	0.17	0.08	0.11	13
349	0.88	0.29	0.44	24
350	0.75	0.44	0.56	27
351	0.42	0.12	0.18	43
352	0.25	0.03	0.06	30
353	0.45	0.41	0.43	22
354	0.19	0.10	0.13	31
355	0.62	0.80	0.70	10
356	0.00	0.00	0.00	20
357	0.65	0.65	0.65	20
358	0.61	0.39	0.48	28
359	0.59	0.48	0.53	21
360	0.22	0.08	0.12	25
361	0.52	0.49	0.50	35
362	0.78	0.69	0.74	36
363	0.36	0.24	0.29	17
364	1.00	0.46	0.63	13
365	0.20	0.05	0.08	21
366	0.43	0.17	0.24	18
367	0.44	0.07	0.12	97
368	0.57	0.45	0.50	29
369	0.60	0.75	0.67	12
370	0.22	0.15	0.18	13
371	0.20	0.11	0.14	18
372	0.67	0.33	0.44	6
373	0.40	0.33	0.36	6
374	0.62	0.17	0.26	30
375	0.19	0.19	0.19	27
376	0.20	0.04	0.06	28
377	0.00	0.00	0.00	2
378	0.20	0.25	0.22	4
379	0.25	0.05	0.09	19
380	0.20	0.20	0.20	5
381	0.58	0.39	0.47	18
382	0.50	0.41	0.45	22
383	0.20	0.06	0.10	16
384	0.57	0.31	0.40	13
385	0.50	0.17	0.25	18
386	0.77	0.91	0.83	11
387	0.46	0.45	0.46	88
388	0.10	0.08	0.09	13
389	0.00	0.00	0.00	6
390	0.00	0.00	0.00	6
391	0.95	0.71	0.81	51
392	0.00	0.00	0.00	13
393	0.50	0.35	0.41	37
394	0.00	0.00	0.00	6
395	0.00	0.00	0.00	9
396	0.00	0.00	0.00	13
397	0.75	0.50	0.60	6
398	0.52	0.41	0.46	29
399	0.89	0.73	0.80	33
400	0.33	0.10	0.15	31
401	0.56	0.10	0.17	50
402	0.85	0.61	0.71	18
403	0.17	0.14	0.15	7
404	0.64	0.62	0.63	26
405	0.84	0.82	0.83	56
406	0.60	0.75	0.67	4
407	0.08	0.06	0.07	17
408	0.75	0.55	0.63	11
409	0.10	0.06	0.07	18
410	0.33	0.30	0.32	10
411	0.40	0.13	0.20	45
412	0.82	0.45	0.58	20
413	0.40	0.16	0.23	25
414	0.00	0.00	0.00	20
415	0.00	0.00	0.00	6
416	0.20	0.12	0.15	26
417	0.60	0.30	0.40	10
418	0.00	0.00	0.00	18
419	0.75	0.50	0.60	6
420	0.56	0.53	0.55	17
421	0.00	0.00	0.00	1
422	0.00	0.00	0.00	6

Assignment Stackoverflow tag predictor				
423	0.00	0.00	0.00	12
424	1.00	0.50	0.67	4
425	0.60	0.27	0.37	11
426	0.17	0.09	0.12	11
427	0.86	0.75	0.80	8
428	0.64	0.27	0.38	26
429	0.52	0.62	0.57	40
430	0.00	0.00	0.00	2
431	0.08	0.03	0.04	35
432	0.71	0.33	0.45	15
433	0.00	0.00	0.00	18
434	0.00	0.00	0.00	0
435	0.00	0.00	0.00	0
436	0.38	0.18	0.24	28
437	0.33	0.15	0.21	33
438	0.79	0.55	0.65	20
439	0.27	0.08	0.13	36
440	0.18	0.11	0.14	18
441	0.42	0.56	0.48	18
442	0.69	0.69	0.69	16
443	0.00	0.00	0.00	22
444	0.00	0.00	0.00	6
445	0.72	0.62	0.67	21
446	0.79	0.57	0.66	46
447	0.19	0.06	0.09	69
448	0.00	0.00	0.00	7
449	0.00	0.00	0.00	3
450	0.12	0.04	0.06	52
451	0.14	0.06	0.09	16
452	0.89	0.94	0.91	17
453	0.00	0.00	0.00	13
454	0.33	0.18	0.24	11
455	0.00	0.00	0.00	12
456	0.12	0.17	0.14	6
457	0.22	0.11	0.15	18
458	0.00	0.00	0.00	15
459	0.95	0.64	0.77	28
460	0.14	0.06	0.08	18
461	0.57	0.40	0.47	10
462	0.40	0.08	0.14	24
463	0.00	0.00	0.00	18
464	0.96	0.62	0.75	39
465	0.21	0.27	0.24	11
466	0.18	0.06	0.09	35
467	0.07	0.05	0.06	21
468	0.25	0.03	0.05	37
469	0.00	0.00	0.00	5
470	0.00	0.00	0.00	8
471	0.53	0.27	0.36	37
472	0.00	0.00	0.00	47
473	0.46	0.43	0.44	14
474	0.88	0.65	0.75	23
475	0.51	0.50	0.50	66
476	0.00	0.00	0.00	3
477	0.70	0.37	0.48	19
478	0.00	0.00	0.00	1
479	0.17	0.13	0.15	23
480	0.54	0.12	0.19	60
481	0.33	0.15	0.21	26
482	0.50	0.50	0.50	4
483	0.00	0.00	0.00	8
484	0.91	0.43	0.59	23
485	0.64	0.39	0.48	18
486	0.62	0.42	0.50	12
487	0.79	0.38	0.51	29
488	1.00	1.00	1.00	1
489	0.00	0.00	0.00	6
490	0.33	0.14	0.20	7
491	0.00	0.00	0.00	3
492	0.12	0.20	0.15	10
493	0.38	0.32	0.34	19
494	0.20	0.14	0.17	7
495	0.43	0.38	0.40	8
496	0.39	0.39	0.39	18
497	0.38	0.12	0.19	72
498	0.17	0.12	0.14	8
499	0.52	0.41	0.46	32
micro avg	0.58	0.36	0.45	37472
macro avg	0.42	0.29	0.33	37472
weighted avg	0.55	0.36	0.43	37472
samples avg	0.43	0.36	0.36	37472
Time taken to run this cell : 0:33:34.684806				

## 2. Perform hyperparam tuning on alpha (or lambda) for Logistic regression to improve the performance using GridSearch

```
In [ ]: # Train
        from sklearn.model_selection import GridSearchCV
        start = datetime.now()

        param={"estimator__C":[0.0001,0.001,0.01,0.1,1,10,100]} # When you use nested estimators with grid search you can scope the parameters with __
        as a separator

        lr_ovr = OneVsRestClassifier(LogisticRegression(C=1.0,penalty='l1', n_jobs=-1),)
        classifier_2=GridSearchCV(estimator=lr_ovr, param_grid=param ,scoring="f1_micro", return_train_score=True)
        classifier_2.fit(x_train_multilabel, y_train)

        print("Time taken to run this cell :", datetime.now() - start)

In [3]: import pickle
        """file=open("gridsearch.pkl", 'wb')
        pickle.dump(classifier_2,file)
        file.close()
        """

        file=open("gridsearch.pkl", 'rb')
        gridsearch=pickle.load(file)
```



```
In [4]: # CV Score
        gridsearch.cv_results_
```

```
{'mean_fit_time': array([ 341.93791715,  363.59180037,  423.69569087,  678.68307408,
                        935.50097712, 1013.79868793, 1081.59573984]),
 'std_fit_time': array([96.9851387 , 52.27677961, 19.59633154, 50.61290431, 42.16038204,
                        37.69262534, 33.27912207]),
 'mean_score_time': array([3.76426148, 3.77001405, 3.71273176, 3.73366205, 3.7477115 ,
                        3.70152036, 3.7257247 ]),
 'std_score_time': array([0.200987 , 0.23564235, 0.22734413, 0.21825075, 0.23177296,
                        0.18633856, 0.21896373]),
 'param_estimator__C': masked_array(data=[0.0001, 0.001, 0.01, 0.1, 1, 10, 100],
                                     mask=[False, False, False, False, False, False, False],
                                     fill_value='?',
                                     dtype=object),
 'params': [{ 'estimator__C': 0.0001},
            { 'estimator__C': 0.001},
            { 'estimator__C': 0.01},
            { 'estimator__C': 0.1},
            { 'estimator__C': 1},
            { 'estimator__C': 10},
            { 'estimator__C': 100}],
 'split0_test_score': array([2.01804129e-04, 8.63213305e-02, 2.61891013e-01, 3.86039087e-01,
                        4.24427405e-01, 4.22475698e-01, 4.17827891e-01]),
 'split1_test_score': array([2.49745052e-04, 7.40314386e-02, 2.35691296e-01, 3.93431914e-01,
                        4.28738496e-01, 4.24752295e-01, 4.14620536e-01]),
 'split2_test_score': array([0.          , 0.05298808, 0.39069205, 0.50160225, 0.52290911,
                        0.52000072, 0.51497723]),
 'mean_test_score': array([1.50518275e-04, 7.11138427e-02, 2.96090271e-01, 4.27023484e-01,
                        4.58690868e-01, 4.55742102e-01, 4.49141063e-01]),
 'std_test_score': array([0.00010822, 0.0137637 , 0.06774206, 0.05282046, 0.04544424 ,
                        0.04544636, 0.04657074]),
 'rank_test_score': array([7, 6, 5, 4, 1, 2, 3], dtype=int32),
 'split0_train_score': array([0.00404188, 0.27506444, 0.42659015, 0.54322329, 0.97229569,
                        0.99788432, 0.99789373]),
 'split1_train_score': array([0.00373521, 0.26666264, 0.42668838, 0.54472801, 0.97188592,
                        0.99821684, 0.99823488]),
 'split2_train_score': array([0.          , 0.15437084, 0.34208662, 0.49453785, 0.96709493,
                        0.99865152, 0.99865154]),
 'mean_train_score': array([0.00259237, 0.23203264, 0.39845505, 0.52749638, 0.97042551,
                        0.9982509 , 0.99826005]),
 'std_train_score': array([0.00183735, 0.0550222 , 0.03985852, 0.0233133 , 0.00236101,
                        0.00031413, 0.00030988])}
```

```
In [7]: # best score and hyperparameter
        print("Best Parameter:",gridsearch.best_params_)
        print("Best F1 micro Score:",gridsearch.best_score_)
```

```
Best Parameter: {'estimator__C': 1}
Best F1 micro Score: 0.45869086799788344
```

```
In [38]: # Test
# Prediction using best score Logistic regression
predictions_2 = gridsearch.predict(x_test_multilabel)

print("Accuracy :",metrics.accuracy_score(y_test, predictions_2))
print("Hamming loss ",metrics.hamming_loss(y_test,predictions_2))

precision = precision_score(y_test, predictions_2, average='micro')
recall = recall_score(y_test, predictions_2, average='micro')
f1 = f1_score(y_test, predictions_2, average='micro')

print("Micro-average quality numbers")
print("Precision: {:.4f}, Recall: {:.4f}, F1-measure: {:.4f}".format(precision, recall, f1))

precision = precision_score(y_test, predictions_2, average='macro')
recall = recall_score(y_test, predictions_2, average='macro')
f1 = f1_score(y_test, predictions_2, average='macro')

print("Macro-average quality numbers")
print("Precision: {:.4f}, Recall: {:.4f}, F1-measure: {:.4f}".format(precision, recall, f1))

print (metrics.classification_report(y_test, predictions_2))
```

Accuracy : 0.1743

Hamming loss 0.0033586

Micro-average quality numbers

Precision: 0.5828, Recall: 0.3650, F1-measure: 0.4488

Macro-average quality numbers

Precision: 0.4206, Recall: 0.2851, F1-measure: 0.3288

	precision	recall	f1-score	support
0	0.69	0.39	0.50	820
1	0.53	0.32	0.40	1931
2	0.37	0.18	0.24	544
3	0.51	0.21	0.29	222
4	0.70	0.51	0.59	1311
5	0.75	0.52	0.61	1014
6	0.66	0.44	0.53	1374
7	0.73	0.59	0.65	702
8	0.90	0.63	0.74	1424
9	0.75	0.64	0.69	1037
10	0.72	0.57	0.64	797
11	0.55	0.38	0.45	156
12	0.57	0.36	0.44	36
13	0.67	0.41	0.51	610
14	0.41	0.24	0.30	405
15	0.61	0.24	0.34	144
16	0.49	0.25	0.33	425
17	0.58	0.32	0.41	485
18	0.73	0.65	0.69	269
19	0.85	0.61	0.71	518
20	0.49	0.29	0.36	529
21	0.82	0.57	0.68	294
22	0.80	0.41	0.54	520
23	0.45	0.28	0.35	246
24	0.54	0.37	0.44	312
25	0.46	0.33	0.38	314
26	0.56	0.30	0.39	190
27	0.31	0.12	0.17	342
28	0.36	0.26	0.30	96
29	0.29	0.16	0.20	32
30	0.64	0.47	0.54	747
31	0.45	0.36	0.40	14
32	0.62	0.61	0.62	166
33	0.56	0.35	0.43	171
34	0.54	0.31	0.39	256
35	0.79	0.55	0.65	199
36	0.15	0.08	0.11	60
37	0.25	0.19	0.22	203
38	0.68	0.49	0.57	201
39	0.40	0.31	0.35	208
40	0.25	0.15	0.19	13
41	0.35	0.16	0.22	154
42	0.35	0.30	0.33	69
43	0.29	0.20	0.24	426
44	0.44	0.27	0.34	77
45	0.47	0.29	0.36	223
46	0.51	0.33	0.40	144
47	0.69	0.49	0.57	245
48	0.42	0.20	0.27	91
49	0.59	0.41	0.48	157
50	0.90	0.67	0.77	132
51	0.84	0.66	0.74	41
52	0.56	0.42	0.48	124
53	0.23	0.26	0.24	96
54	0.18	0.12	0.15	128
55	0.50	0.24	0.32	46
56	0.66	0.64	0.65	151
57	0.08	0.01	0.02	80
58	0.32	0.17	0.22	65
59	0.37	0.16	0.23	182
60	0.90	0.69	0.78	148
61	0.36	0.14	0.20	196
62	0.27	0.21	0.24	58
63	0.86	0.28	0.42	43
64	0.61	0.34	0.44	197
65	0.65	0.43	0.51	82
66	0.69	0.54	0.61	50
67	0.59	0.54	0.56	105
68	0.16	0.05	0.08	98
69	0.21	0.07	0.10	238
70	0.25	0.09	0.13	35
71	0.51	0.50	0.50	54
72	0.00	0.00	0.00	25
73	0.29	0.24	0.26	29
74	0.20	0.10	0.14	29
75	0.26	0.23	0.24	40
76	0.77	0.55	0.64	105
77	0.58	0.50	0.54	28
78	0.18	0.09	0.12	202
79	0.54	0.41	0.46	37
80	0.50	0.33	0.40	15
81	0.48	0.27	0.35	52
82	0.38	0.28	0.32	50
83	0.21	0.05	0.09	56
84	0.73	0.59	0.65	54
85	0.58	0.62	0.60	34
86	0.23	0.20	0.21	30
87	0.56	0.34	0.43	29
88	0.71	0.83	0.77	24
89	0.83	0.79	0.81	117
90	0.11	0.06	0.08	66
91	0.39	0.25	0.30	68
92	0.67	0.30	0.41	67
93	0.53	0.36	0.43	28
94	0.42	0.29	0.34	17
95	0.74	0.49	0.59	51
96	0.57	0.43	0.49	53
97	0.08	0.02	0.03	61
98	0.08	0.03	0.04	79

Assignment Stackoverflow tag predictor				
99	0.47	0.44	0.46	18
100	0.50	0.09	0.15	11
101	0.62	0.58	0.60	207
102	0.00	0.00	0.00	6
103	0.25	0.03	0.06	30
104	0.29	0.09	0.14	54
105	0.70	0.41	0.52	39
106	0.29	0.13	0.18	70
107	0.40	0.14	0.21	14
108	0.58	0.17	0.26	66
109	0.53	0.34	0.41	50
110	0.56	0.26	0.36	87
111	0.40	0.43	0.42	51
112	0.86	0.06	0.12	291
113	0.97	0.76	0.85	49
114	0.32	0.10	0.15	110
115	0.17	0.04	0.06	28
116	0.00	0.00	0.00	5
117	0.25	0.09	0.13	56
118	0.74	0.45	0.56	125
119	0.70	0.43	0.54	44
120	0.75	0.36	0.48	42
121	0.40	0.22	0.28	55
122	0.67	0.43	0.52	68
123	0.16	0.10	0.12	82
124	0.00	0.00	0.00	0
125	0.71	0.71	0.71	7
126	0.12	0.06	0.08	18
127	0.40	0.13	0.20	31
128	0.75	0.46	0.57	13
129	0.64	0.54	0.59	50
130	0.19	0.10	0.13	91
131	0.64	0.60	0.62	35
132	0.21	0.12	0.15	26
133	0.25	0.06	0.10	32
134	0.61	0.40	0.48	35
135	0.76	0.68	0.71	37
136	0.00	0.00	0.00	55
137	0.24	0.39	0.30	41
138	0.38	0.40	0.39	15
139	0.28	0.14	0.19	99
140	0.87	0.70	0.77	86
141	0.45	0.25	0.32	53
142	0.75	0.08	0.15	36
143	0.52	0.52	0.52	66
144	0.53	0.47	0.50	64
145	0.27	0.12	0.17	25
146	0.15	0.10	0.12	125
147	0.24	0.27	0.25	15
148	0.64	0.52	0.57	48
149	0.34	0.26	0.30	65
150	0.00	0.00	0.00	11
151	0.33	0.33	0.33	15
152	0.21	0.13	0.16	52
153	0.44	0.39	0.41	18
154	0.43	0.19	0.26	16
155	0.27	0.20	0.23	20
156	0.47	0.22	0.30	121
157	0.51	0.31	0.38	107
158	0.00	0.00	0.00	15
159	0.67	0.50	0.57	105
160	0.46	0.39	0.42	69
161	0.54	0.36	0.43	56
162	0.25	0.09	0.13	47
163	0.04	0.01	0.01	121
164	0.39	0.29	0.33	41
165	0.00	0.00	0.00	229
166	0.71	0.30	0.42	98
167	0.39	0.21	0.27	33
168	0.53	0.18	0.27	44
169	0.70	0.47	0.56	45
170	0.84	0.41	0.55	51
171	0.00	0.00	0.00	18
172	0.49	0.46	0.47	48
173	0.33	0.42	0.37	12
174	0.29	0.16	0.21	62
175	0.72	0.52	0.61	44
176	0.92	0.77	0.84	30
177	0.48	0.43	0.46	30
178	0.00	0.00	0.00	0
179	1.00	1.00	1.00	1
180	0.52	0.30	0.38	40
181	0.17	0.07	0.10	44
182	0.50	0.50	0.50	2
183	0.53	0.37	0.44	75
184	0.25	0.25	0.25	4
185	0.50	0.23	0.32	64
186	0.23	0.25	0.24	12
187	0.95	0.64	0.76	55
188	0.78	0.66	0.71	64
189	0.41	0.15	0.22	96
190	0.11	0.05	0.06	22
191	0.81	0.17	0.28	76
192	0.68	0.42	0.52	45
193	0.86	0.43	0.57	14
194	0.55	0.46	0.50	50
195	0.82	0.45	0.58	20
196	0.81	0.63	0.71	35
197	0.50	0.33	0.40	94
198	0.00	0.00	0.00	14
199	0.12	0.04	0.06	25
200	0.50	0.17	0.25	54
201	0.25	0.09	0.13	22
202	0.30	0.26	0.28	43
203	0.14	0.02	0.04	43
204	0.98	0.65	0.78	62
205	0.00	0.00	0.00	3
206	0.14	0.07	0.09	43

207	0.33	0.14	0.20	7
208	0.20	0.12	0.15	8
209	0.56	0.12	0.20	42
210	0.22	0.40	0.29	10
211	0.35	0.20	0.25	40
212	0.73	0.48	0.58	23
213	0.00	0.00	0.00	6
214	0.63	0.47	0.54	47
215	0.38	0.13	0.19	62
216	0.62	0.42	0.50	77
217	0.18	0.09	0.12	22
218	0.33	0.33	0.33	3
219	0.06	0.04	0.05	28
220	0.67	0.07	0.13	81
221	0.24	0.13	0.17	31
222	0.17	0.06	0.09	34
223	0.96	0.45	0.61	60
224	0.33	0.30	0.32	10
225	0.75	0.60	0.67	10
226	0.75	0.76	0.76	92
227	0.89	0.62	0.73	13
228	0.40	0.15	0.22	13
229	0.85	0.77	0.80	43
230	0.29	0.17	0.21	35
231	0.00	0.00	0.00	4
232	0.25	0.10	0.14	20
233	0.47	0.32	0.38	145
234	0.84	0.56	0.67	55
235	0.00	0.00	0.00	2
236	0.27	0.08	0.12	37
237	0.69	0.42	0.52	90
238	0.50	0.19	0.27	58
239	0.50	0.25	0.33	20
240	0.89	0.69	0.78	61
241	0.78	0.74	0.76	42
242	0.56	0.63	0.59	30
243	0.80	0.53	0.64	66
244	0.56	0.24	0.33	42
245	0.10	0.06	0.08	31
246	1.00	0.50	0.67	6
247	0.25	0.17	0.20	18
248	0.83	0.57	0.67	51
249	0.57	0.47	0.52	17
250	0.62	0.59	0.60	22
251	0.76	0.42	0.54	52
252	0.62	0.17	0.27	29
253	0.11	0.07	0.09	28
254	0.00	0.00	0.00	10
255	0.20	0.20	0.20	5
256	0.25	0.33	0.29	3
257	0.64	0.34	0.44	41
258	0.23	0.10	0.14	30
259	1.00	0.67	0.80	3
260	0.00	0.00	0.00	38
261	0.00	0.00	0.00	1
262	0.46	0.32	0.37	19
263	0.00	0.00	0.00	14
264	0.07	0.05	0.06	37
265	0.11	0.11	0.11	9
266	0.20	0.24	0.22	45
267	0.64	0.55	0.59	33
268	0.81	0.81	0.81	16
269	0.47	0.46	0.46	35
270	0.60	0.27	0.37	11
271	0.00	0.00	0.00	30
272	0.30	0.38	0.33	8
273	0.12	0.14	0.13	21
274	0.46	0.31	0.37	123
275	0.38	0.25	0.30	67
276	0.89	0.80	0.84	20
277	0.00	0.00	0.00	14
278	0.33	0.16	0.21	19
279	0.73	0.67	0.70	12
280	0.00	0.00	0.00	15
281	0.92	0.65	0.76	17
282	0.94	0.71	0.81	41
283	0.64	0.47	0.54	15
284	0.51	0.34	0.41	74
285	0.38	0.13	0.20	38
286	0.13	0.12	0.13	16
287	0.29	0.07	0.11	30
288	0.90	0.64	0.75	28
289	0.00	0.00	0.00	21
290	0.80	0.59	0.68	41
291	0.10	0.08	0.09	12
292	0.41	0.29	0.34	24
293	0.47	0.35	0.40	20
294	0.21	0.22	0.21	23
295	0.00	0.00	0.00	29
296	0.25	0.11	0.15	28
297	0.36	0.29	0.32	42
298	0.19	0.06	0.09	53
299	0.00	0.00	0.00	36
300	0.21	0.12	0.15	41
301	0.53	0.46	0.49	37
302	0.88	0.58	0.70	26
303	0.20	0.09	0.13	11
304	0.33	0.23	0.27	31
305	0.33	0.29	0.31	17
306	0.40	0.22	0.29	9
307	0.50	0.33	0.40	6
308	0.00	0.00	0.00	34
309	0.61	0.40	0.48	43
310	0.06	0.03	0.04	30
311	0.33	0.14	0.20	50
312	0.20	0.04	0.07	24
313	0.38	0.14	0.21	42
314	0.42	0.23	0.29	22

315	0.00	0.00	0.00	58
316	0.50	0.10	0.17	10
317	0.38	0.26	0.31	57
318	0.57	0.40	0.47	10
319	0.17	0.09	0.12	11
320	0.14	0.18	0.16	11
321	0.25	0.12	0.17	8
322	0.56	0.41	0.47	22
323	0.79	0.79	0.79	28
324	0.63	0.58	0.60	50
325	0.29	0.11	0.16	18
326	0.18	0.09	0.12	33
327	0.16	0.18	0.17	17
328	0.36	0.17	0.23	29
329	0.33	0.14	0.20	7
330	0.42	0.50	0.45	10
331	0.19	0.20	0.19	25
332	1.00	1.00	1.00	2
333	0.71	0.45	0.56	11
334	0.00	0.00	0.00	24
335	0.33	0.20	0.25	5
336	0.17	0.03	0.05	33
337	0.45	0.17	0.24	30
338	0.91	0.71	0.80	42
339	0.22	0.08	0.11	26
340	0.48	0.36	0.41	36
341	1.00	0.54	0.70	13
342	0.60	0.55	0.57	11
343	0.43	0.30	0.35	10
344	0.14	0.05	0.07	21
345	0.00	0.00	0.00	0
346	0.00	0.00	0.00	6
347	0.00	0.00	0.00	12
348	0.17	0.08	0.11	13
349	0.88	0.29	0.44	24
350	0.75	0.44	0.56	27
351	0.36	0.09	0.15	43
352	0.25	0.03	0.06	30
353	0.45	0.41	0.43	22
354	0.19	0.10	0.13	31
355	0.62	0.80	0.70	10
356	0.00	0.00	0.00	20
357	0.65	0.65	0.65	20
358	0.61	0.39	0.48	28
359	0.59	0.48	0.53	21
360	0.22	0.08	0.12	25
361	0.52	0.49	0.50	35
362	0.78	0.69	0.74	36
363	0.36	0.24	0.29	17
364	1.00	0.46	0.63	13
365	0.20	0.05	0.08	21
366	0.43	0.17	0.24	18
367	0.43	0.06	0.11	97
368	0.57	0.45	0.50	29
369	0.60	0.75	0.67	12
370	0.22	0.15	0.18	13
371	0.20	0.11	0.14	18
372	0.67	0.33	0.44	6
373	0.40	0.33	0.36	6
374	0.62	0.17	0.26	30
375	0.19	0.19	0.19	27
376	0.20	0.04	0.06	28
377	0.00	0.00	0.00	2
378	0.20	0.25	0.22	4
379	0.25	0.05	0.09	19
380	0.20	0.20	0.20	5
381	0.58	0.39	0.47	18
382	0.50	0.41	0.45	22
383	0.20	0.06	0.10	16
384	0.57	0.31	0.40	13
385	0.50	0.17	0.25	18
386	0.77	0.91	0.83	11
387	0.46	0.45	0.46	88
388	0.10	0.08	0.09	13
389	0.00	0.00	0.00	6
390	0.00	0.00	0.00	6
391	0.95	0.71	0.81	51
392	0.00	0.00	0.00	13
393	0.50	0.35	0.41	37
394	0.00	0.00	0.00	6
395	0.00	0.00	0.00	9
396	0.00	0.00	0.00	13
397	0.75	0.50	0.60	6
398	0.52	0.41	0.46	29
399	0.89	0.73	0.80	33
400	0.33	0.10	0.15	31
401	0.56	0.10	0.17	50
402	0.85	0.61	0.71	18
403	0.17	0.14	0.15	7
404	0.64	0.62	0.63	26
405	0.84	0.82	0.83	56
406	0.60	0.75	0.67	4
407	0.08	0.06	0.07	17
408	0.75	0.55	0.63	11
409	0.10	0.06	0.07	18
410	0.33	0.30	0.32	10
411	0.40	0.13	0.20	45
412	0.82	0.45	0.58	20
413	0.40	0.16	0.23	25
414	0.00	0.00	0.00	20
415	0.00	0.00	0.00	6
416	0.20	0.12	0.15	26
417	0.60	0.30	0.40	10
418	0.00	0.00	0.00	18
419	0.75	0.50	0.60	6
420	0.56	0.53	0.55	17
421	0.00	0.00	0.00	1
422	0.00	0.00	0.00	6

Assignment Stackoverflow tag predictor				
423	0.00	0.00	0.00	12
424	1.00	0.50	0.67	4
425	0.60	0.27	0.37	11
426	0.17	0.09	0.12	11
427	0.86	0.75	0.80	8
428	0.64	0.27	0.38	26
429	0.52	0.62	0.57	40
430	0.00	0.00	0.00	2
431	0.08	0.03	0.04	35
432	0.71	0.33	0.45	15
433	0.00	0.00	0.00	18
434	0.00	0.00	0.00	0
435	0.00	0.00	0.00	0
436	0.38	0.18	0.24	28
437	0.33	0.15	0.21	33
438	0.79	0.55	0.65	20
439	0.27	0.08	0.13	36
440	0.17	0.11	0.13	18
441	0.42	0.56	0.48	18
442	0.69	0.69	0.69	16
443	0.00	0.00	0.00	22
444	0.00	0.00	0.00	6
445	0.72	0.62	0.67	21
446	0.79	0.57	0.66	46
447	0.19	0.06	0.09	69
448	0.00	0.00	0.00	7
449	0.00	0.00	0.00	3
450	0.12	0.04	0.06	52
451	0.14	0.06	0.09	16
452	0.89	0.94	0.91	17
453	0.00	0.00	0.00	13
454	0.33	0.18	0.24	11
455	0.00	0.00	0.00	12
456	0.12	0.17	0.14	6
457	0.22	0.11	0.15	18
458	0.00	0.00	0.00	15
459	0.95	0.64	0.77	28
460	0.14	0.06	0.08	18
461	0.57	0.40	0.47	10
462	0.40	0.08	0.14	24
463	0.00	0.00	0.00	18
464	0.96	0.62	0.75	39
465	0.21	0.27	0.24	11
466	0.18	0.06	0.09	35
467	0.07	0.05	0.06	21
468	0.25	0.03	0.05	37
469	0.00	0.00	0.00	5
470	0.00	0.00	0.00	8
471	0.53	0.27	0.36	37
472	0.00	0.00	0.00	47
473	0.46	0.43	0.44	14
474	0.88	0.65	0.75	23
475	0.51	0.50	0.50	66
476	0.00	0.00	0.00	3
477	0.70	0.37	0.48	19
478	0.00	0.00	0.00	1
479	0.17	0.13	0.15	23
480	0.54	0.12	0.19	60
481	0.33	0.15	0.21	26
482	0.50	0.50	0.50	4
483	0.00	0.00	0.00	8
484	0.91	0.43	0.59	23
485	0.64	0.39	0.48	18
486	0.62	0.42	0.50	12
487	0.79	0.38	0.51	29
488	1.00	1.00	1.00	1
489	0.00	0.00	0.00	6
490	0.33	0.14	0.20	7
491	0.00	0.00	0.00	3
492	0.12	0.20	0.15	10
493	0.38	0.32	0.34	19
494	0.20	0.14	0.17	7
495	0.43	0.38	0.40	8
496	0.39	0.39	0.39	18
497	0.38	0.12	0.19	72
498	0.17	0.12	0.14	8
499	0.50	0.41	0.45	32
micro avg	0.58	0.36	0.45	37472
macro avg	0.42	0.29	0.33	37472
weighted avg	0.55	0.36	0.43	37472
samples avg	0.43	0.36	0.36	37472

3. Try OneVsRestClassifier with Linear-SVM (SGDClassifier with loss-hinge) USING GridSearch</li>

```
In [17]: # Train
from sklearn.model_selection import GridSearchCV
start = datetime.now()

param={"estimator__alpha":[0.0001,0.001,0.01,0.1,1,10,100]} # When you use nested estimators with grid search you can scope the parameters with __ as a separator

lr_ovr = OneVsRestClassifier(SGDClassifier(loss='hinge', penalty='l1',n_jobs=-1),)
classifier_2=GridSearchCV(estimator=lr_ovr, param_grid=param ,scoring="f1_micro", return_train_score=True)
classifier_2.fit(x_train_multilabel, y_train)

print("Time taken to run this cell :", datetime.now() - start)

Time taken to run this cell : 2:08:38.593076

In [19]: # Saving Result
import pickle
"""file=open("gridsearch_svm.pkl", 'wb')
pickle.dump(classifier_2,file)
file.close()
"""
file=open("gridsearch_svm.pkl", 'rb')
gridsearch_svm=pickle.load(file)
```

```
In [20]: # Test
# Prediction using best score SVM
predictions_2 = gridsearch_svm.predict(x_test_multilabel)

print("Accuracy :",metrics.accuracy_score(y_test, predictions_2))
print("Hamming loss ",metrics.hamming_loss(y_test,predictions_2))

precision = precision_score(y_test, predictions_2, average='micro')
recall = recall_score(y_test, predictions_2, average='micro')
f1 = f1_score(y_test, predictions_2, average='micro')

print("Micro-average quality numbers")
print("Precision: {:.4f}, Recall: {:.4f}, F1-measure: {:.4f}".format(precision, recall, f1))

precision = precision_score(y_test, predictions_2, average='macro')
recall = recall_score(y_test, predictions_2, average='macro')
f1 = f1_score(y_test, predictions_2, average='macro')

print("Macro-average quality numbers")
print("Precision: {:.4f}, Recall: {:.4f}, F1-measure: {:.4f}".format(precision, recall, f1))

print (metrics.classification_report(y_test, predictions_2))
```



Accuracy : 0.13035

Hamming loss 0.0036607

Micro-average quality numbers

Precision: 0.5228, Recall: 0.2643, F1-measure: 0.3511

Macro-average quality numbers

Precision: 0.2781, Recall: 0.2035, F1-measure: 0.2115

	precision	recall	f1-score	support
0	0.64	0.39	0.49	820
1	0.66	0.03	0.06	1931
2	0.38	0.16	0.23	544
3	0.56	0.33	0.41	222
4	0.70	0.40	0.51	1311
5	0.79	0.53	0.63	1014
6	0.73	0.40	0.52	1374
7	0.74	0.54	0.62	702
8	0.77	0.57	0.66	1424
9	0.73	0.19	0.30	1037
10	0.69	0.41	0.51	797
11	0.46	0.43	0.44	156
12	0.38	0.33	0.35	36
13	0.74	0.40	0.52	610
14	0.39	0.02	0.03	405
15	0.41	0.22	0.28	144
16	0.65	0.21	0.32	425
17	0.62	0.18	0.27	485
18	0.48	0.42	0.45	269
19	0.84	0.62	0.71	518
20	0.50	0.24	0.32	529
21	0.64	0.68	0.66	294
22	0.80	0.48	0.60	520
23	0.55	0.26	0.35	246
24	0.41	0.06	0.11	312
25	0.71	0.02	0.03	314
26	0.55	0.37	0.44	190
27	0.00	0.00	0.00	342
28	0.22	0.21	0.21	96
29	0.38	0.16	0.22	32
30	0.39	0.09	0.15	747
31	0.32	0.57	0.41	14
32	0.40	0.55	0.46	166
33	0.59	0.30	0.40	171
34	0.49	0.31	0.38	256
35	0.62	0.65	0.64	199
36	0.00	0.00	0.00	60
37	0.00	0.00	0.00	203
38	0.50	0.31	0.38	201
39	0.00	0.00	0.00	208
40	0.05	0.08	0.06	13
41	0.46	0.15	0.23	154
42	0.26	0.14	0.19	69
43	0.00	0.00	0.00	426
44	0.00	0.00	0.00	77
45	0.33	0.06	0.11	223
46	0.68	0.22	0.34	144
47	0.76	0.50	0.60	245
48	0.50	0.12	0.19	91
49	0.38	0.31	0.34	157
50	0.82	0.77	0.79	132
51	0.72	0.68	0.70	41
52	0.44	0.50	0.47	124
53	0.00	0.00	0.00	96
54	0.00	0.00	0.00	128
55	0.62	0.50	0.55	46
56	0.60	0.58	0.59	151
57	0.00	0.00	0.00	80
58	0.00	0.00	0.00	65
59	0.00	0.00	0.00	182
60	0.77	0.70	0.73	148
61	0.22	0.17	0.19	196
62	0.00	0.00	0.00	58
63	0.75	0.35	0.48	43
64	0.30	0.29	0.30	197
65	0.47	0.52	0.50	82
66	0.00	0.00	0.00	50
67	0.49	0.68	0.57	105
68	0.00	0.00	0.00	98
69	0.00	0.00	0.00	238
70	0.09	0.06	0.07	35
71	0.31	0.26	0.28	54
72	0.00	0.00	0.00	25
73	0.44	0.14	0.21	29
74	0.00	0.00	0.00	29
75	0.53	0.20	0.29	40
76	0.66	0.70	0.68	105
77	0.27	0.25	0.26	28
78	0.33	0.07	0.11	202
79	0.40	0.51	0.45	37
80	0.15	0.40	0.22	15
81	0.30	0.37	0.33	52
82	0.33	0.26	0.29	50
83	0.00	0.00	0.00	56
84	0.55	0.54	0.54	54
85	0.53	0.26	0.35	34
86	0.24	0.23	0.24	30
87	0.23	0.10	0.14	29
88	0.42	0.67	0.52	24
89	0.73	0.72	0.72	117
90	0.00	0.00	0.00	66
91	0.34	0.21	0.26	68
92	0.67	0.12	0.20	67
93	0.32	0.36	0.34	28
94	0.14	0.29	0.19	17
95	0.33	0.55	0.41	51
96	0.62	0.34	0.44	53
97	0.00	0.00	0.00	61
98	0.00	0.00	0.00	79

Assignment Stackoverflow tag predictor				
99	0.06	0.22	0.09	18
100	0.09	0.27	0.13	11
101	0.56	0.55	0.55	207
102	0.00	0.00	0.00	6
103	0.67	0.07	0.12	30
104	0.00	0.00	0.00	54
105	0.31	0.46	0.37	39
106	0.00	0.00	0.00	70
107	0.75	0.21	0.33	14
108	0.27	0.36	0.31	66
109	0.18	0.42	0.26	50
110	0.54	0.08	0.14	87
111	0.27	0.43	0.33	51
112	0.00	0.00	0.00	291
113	0.83	0.80	0.81	49
114	0.08	0.01	0.02	110
115	0.09	0.11	0.10	28
116	0.00	0.00	0.00	5
117	0.00	0.00	0.00	56
118	0.76	0.49	0.60	125
119	0.50	0.32	0.39	44
120	0.71	0.12	0.20	42
121	0.20	0.29	0.24	55
122	0.71	0.43	0.53	68
123	0.00	0.00	0.00	82
124	0.00	0.00	0.00	0
125	0.83	0.71	0.77	7
126	0.09	0.22	0.12	18
127	0.00	0.00	0.00	31
128	0.60	0.46	0.52	13
129	0.58	0.60	0.59	50
130	0.00	0.00	0.00	91
131	0.36	0.57	0.44	35
132	0.06	0.19	0.09	26
133	0.00	0.00	0.00	32
134	0.50	0.17	0.26	35
135	0.61	0.62	0.61	37
136	0.00	0.00	0.00	55
137	0.17	0.44	0.24	41
138	0.00	0.00	0.00	15
139	0.15	0.08	0.11	99
140	0.88	0.51	0.65	86
141	0.56	0.19	0.28	53
142	0.18	0.17	0.17	36
143	0.55	0.52	0.53	66
144	0.69	0.38	0.48	64
145	0.00	0.00	0.00	25
146	0.00	0.00	0.00	125
147	0.00	0.00	0.00	15
148	0.51	0.58	0.54	48
149	0.18	0.25	0.21	65
150	0.02	0.18	0.04	11
151	0.14	0.33	0.20	15
152	0.00	0.00	0.00	52
153	0.10	0.17	0.13	18
154	1.00	0.06	0.12	16
155	0.00	0.00	0.00	20
156	0.27	0.22	0.24	121
157	0.44	0.52	0.48	107
158	0.00	0.00	0.00	15
159	0.73	0.29	0.41	105
160	0.42	0.22	0.29	69
161	0.29	0.12	0.18	56
162	0.00	0.00	0.00	47
163	0.00	0.00	0.00	121
164	0.39	0.29	0.33	41
165	0.00	0.00	0.00	229
166	0.00	0.00	0.00	98
167	0.78	0.21	0.33	33
168	0.08	0.05	0.06	44
169	0.51	0.58	0.54	45
170	0.83	0.47	0.60	51
171	0.00	0.00	0.00	18
172	0.42	0.56	0.48	48
173	0.11	0.08	0.10	12
174	0.00	0.00	0.00	62
175	0.66	0.66	0.66	44
176	0.30	0.63	0.40	30
177	0.48	0.33	0.39	30
178	0.00	0.00	0.00	0
179	1.00	1.00	1.00	1
180	0.34	0.35	0.35	40
181	0.00	0.00	0.00	44
182	0.05	0.50	0.09	2
183	0.36	0.19	0.25	75
184	0.50	0.25	0.33	4
185	0.33	0.08	0.13	64
186	0.29	0.33	0.31	12
187	0.88	0.55	0.67	55
188	0.71	0.39	0.51	64
189	0.00	0.00	0.00	96
190	0.10	0.14	0.11	22
191	0.56	0.12	0.20	76
192	0.29	0.31	0.30	45
193	0.25	0.07	0.11	14
194	0.47	0.76	0.58	50
195	0.86	0.30	0.44	20
196	0.79	0.74	0.76	35
197	0.55	0.06	0.11	94
198	0.00	0.00	0.00	14
199	0.00	0.00	0.00	25
200	0.00	0.00	0.00	54
201	0.25	0.18	0.21	22
202	0.00	0.00	0.00	43
203	0.25	0.02	0.04	43
204	0.87	0.42	0.57	62
205	0.00	0.00	0.00	3
206	0.00	0.00	0.00	43

207	0.00	0.00	0.00	7
208	0.04	0.12	0.06	8
209	0.00	0.00	0.00	42
210	0.19	0.40	0.26	10
211	0.26	0.35	0.30	40
212	0.28	0.35	0.31	23
213	0.00	0.00	0.00	6
214	0.44	0.57	0.50	47
215	0.00	0.00	0.00	62
216	0.00	0.00	0.00	77
217	0.57	0.18	0.28	22
218	0.00	0.00	0.00	3
219	0.04	0.07	0.05	28
220	0.29	0.05	0.08	81
221	0.00	0.00	0.00	31
222	0.00	0.00	0.00	34
223	0.86	0.30	0.44	60
224	0.00	0.00	0.00	10
225	0.50	0.90	0.64	10
226	0.73	0.82	0.77	92
227	0.00	0.00	0.00	13
228	0.40	0.15	0.22	13
229	0.56	0.63	0.59	43
230	0.28	0.31	0.30	35
231	0.00	0.00	0.00	4
232	0.32	0.30	0.31	20
233	0.00	0.00	0.00	145
234	0.59	0.58	0.59	55
235	0.00	0.00	0.00	2
236	0.00	0.00	0.00	37
237	0.69	0.39	0.50	90
238	0.00	0.00	0.00	58
239	0.80	0.20	0.32	20
240	0.93	0.44	0.60	61
241	0.76	0.81	0.78	42
242	0.14	0.83	0.24	30
243	0.66	0.56	0.61	66
244	0.42	0.36	0.38	42
245	0.00	0.00	0.00	31
246	0.06	0.33	0.10	6
247	0.00	0.00	0.00	18
248	0.46	0.55	0.50	51
249	0.21	0.29	0.24	17
250	0.52	0.50	0.51	22
251	0.63	0.52	0.57	52
252	0.00	0.00	0.00	29
253	0.00	0.00	0.00	28
254	0.00	0.00	0.00	10
255	0.04	0.20	0.06	5
256	0.11	0.67	0.19	3
257	0.18	0.34	0.24	41
258	0.00	0.00	0.00	30
259	0.20	0.33	0.25	3
260	0.00	0.00	0.00	38
261	0.00	0.00	0.00	1
262	0.33	0.26	0.29	19
263	0.00	0.00	0.00	14
264	0.00	0.00	0.00	37
265	0.00	0.00	0.00	9
266	0.00	0.00	0.00	45
267	0.33	0.30	0.32	33
268	0.32	0.62	0.43	16
269	0.42	0.71	0.53	35
270	0.20	0.36	0.26	11
271	0.00	0.00	0.00	30
272	0.00	0.00	0.00	8
273	0.00	0.00	0.00	21
274	0.00	0.00	0.00	123
275	0.29	0.24	0.26	67
276	0.55	0.55	0.55	20
277	0.00	0.00	0.00	14
278	0.00	0.00	0.00	19
279	0.55	0.50	0.52	12
280	0.00	0.00	0.00	15
281	0.65	0.65	0.65	17
282	0.84	0.76	0.79	41
283	0.00	0.00	0.00	15
284	0.79	0.15	0.25	74
285	0.16	0.16	0.16	38
286	0.00	0.00	0.00	16
287	0.00	0.00	0.00	30
288	0.80	0.57	0.67	28
289	0.00	0.00	0.00	21
290	0.88	0.71	0.78	41
291	0.00	0.00	0.00	12
292	0.00	0.00	0.00	24
293	0.16	0.50	0.25	20
294	0.04	0.04	0.04	23
295	0.00	0.00	0.00	29
296	0.00	0.00	0.00	28
297	0.00	0.00	0.00	42
298	0.00	0.00	0.00	53
299	0.00	0.00	0.00	36
300	0.00	0.00	0.00	41
301	0.00	0.00	0.00	37
302	0.68	0.50	0.58	26
303	0.40	0.18	0.25	11
304	0.00	0.00	0.00	31
305	0.33	0.18	0.23	17
306	0.00	0.00	0.00	9
307	0.20	0.17	0.18	6
308	0.00	0.00	0.00	34
309	0.50	0.26	0.34	43
310	0.00	0.00	0.00	30
311	0.00	0.00	0.00	50
312	0.00	0.00	0.00	24
313	0.00	0.00	0.00	42
314	0.43	0.14	0.21	22

315	0.00	0.00	0.00	58
316	0.80	0.40	0.53	10
317	0.28	0.32	0.30	57
318	1.00	0.10	0.18	10
319	0.00	0.00	0.00	11
320	0.07	0.09	0.08	11
321	0.33	0.12	0.18	8
322	0.50	0.36	0.42	22
323	0.83	0.36	0.50	28
324	0.58	0.44	0.50	50
325	0.00	0.00	0.00	18
326	0.00	0.00	0.00	33
327	0.07	0.12	0.09	17
328	0.00	0.00	0.00	29
329	1.00	0.29	0.44	7
330	0.44	0.40	0.42	10
331	0.00	0.00	0.00	25
332	0.18	1.00	0.31	2
333	0.43	0.55	0.48	11
334	0.00	0.00	0.00	24
335	1.00	0.20	0.33	5
336	0.00	0.00	0.00	33
337	0.18	0.10	0.13	30
338	0.94	0.69	0.79	42
339	0.00	0.00	0.00	26
340	0.30	0.39	0.34	36
341	1.00	0.46	0.63	13
342	0.00	0.00	0.00	11
343	0.12	0.10	0.11	10
344	0.00	0.00	0.00	21
345	0.00	0.00	0.00	0
346	0.00	0.00	0.00	6
347	0.00	0.00	0.00	12
348	0.00	0.00	0.00	13
349	0.00	0.00	0.00	24
350	0.33	0.37	0.35	27
351	0.00	0.00	0.00	43
352	0.00	0.00	0.00	30
353	0.43	0.27	0.33	22
354	0.00	0.00	0.00	31
355	0.80	0.40	0.53	10
356	0.60	0.15	0.24	20
357	0.54	0.75	0.63	20
358	0.35	0.46	0.40	28
359	0.30	0.43	0.35	21
360	0.00	0.00	0.00	25
361	0.50	0.31	0.39	35
362	0.71	0.42	0.53	36
363	0.25	0.18	0.21	17
364	1.00	0.15	0.27	13
365	0.00	0.00	0.00	21
366	0.00	0.00	0.00	18
367	0.00	0.00	0.00	97
368	0.35	0.45	0.39	29
369	1.00	0.42	0.59	12
370	0.00	0.00	0.00	13
371	0.06	0.11	0.08	18
372	0.00	0.00	0.00	6
373	0.14	0.33	0.20	6
374	0.00	0.00	0.00	30
375	0.00	0.00	0.00	27
376	0.00	0.00	0.00	28
377	0.00	0.00	0.00	2
378	0.00	0.00	0.00	4
379	0.00	0.00	0.00	19
380	0.00	0.00	0.00	5
381	0.77	0.56	0.65	18
382	0.16	0.23	0.19	22
383	0.01	0.06	0.01	16
384	0.00	0.00	0.00	13
385	0.00	0.00	0.00	18
386	0.67	0.36	0.47	11
387	0.00	0.00	0.00	88
388	0.00	0.00	0.00	13
389	1.00	0.17	0.29	6
390	0.00	0.00	0.00	6
391	1.00	0.20	0.33	51
392	0.00	0.00	0.00	13
393	0.39	0.32	0.35	37
394	0.00	0.00	0.00	6
395	0.00	0.00	0.00	9
396	0.00	0.00	0.00	13
397	0.43	0.50	0.46	6
398	0.48	0.34	0.40	29
399	0.80	0.48	0.60	33
400	0.00	0.00	0.00	31
401	0.00	0.00	0.00	50
402	0.93	0.78	0.85	18
403	0.50	0.29	0.36	7
404	0.57	0.65	0.61	26
405	1.00	0.21	0.35	56
406	1.00	0.75	0.86	4
407	0.00	0.00	0.00	17
408	0.40	0.18	0.25	11
409	0.00	0.00	0.00	18
410	0.40	0.20	0.27	10
411	0.00	0.00	0.00	45
412	0.00	0.00	0.00	20
413	0.00	0.00	0.00	25
414	0.00	0.00	0.00	20
415	0.12	0.33	0.18	6
416	0.11	0.12	0.11	26
417	0.00	0.00	0.00	10
418	0.00	0.00	0.00	18
419	0.00	0.00	0.00	6
420	0.47	0.53	0.50	17
421	0.00	0.00	0.00	1
422	0.00	0.00	0.00	6

8/11/2019	Assignment Stackoverflow tag predictor				
	423	0.00	0.00	0.00	12
	424	1.00	0.25	0.40	4
	425	0.00	0.00	0.00	11
	426	0.00	0.00	0.00	11
	427	0.50	0.25	0.33	8
	428	0.50	0.27	0.35	26
	429	0.40	0.15	0.22	40
	430	0.00	0.00	0.00	2
	431	0.00	0.00	0.00	35
	432	1.00	0.20	0.33	15
	433	0.00	0.00	0.00	18
	434	0.00	0.00	0.00	0
	435	0.00	0.00	0.00	0
	436	0.00	0.00	0.00	28
	437	0.32	0.21	0.25	33
	438	1.00	0.10	0.18	20
	439	0.00	0.00	0.00	36
	440	0.00	0.00	0.00	18
	441	0.27	0.44	0.33	18
	442	0.73	0.50	0.59	16
	443	0.12	0.14	0.13	22
	444	0.00	0.00	0.00	6
	445	0.64	0.33	0.44	21
	446	0.68	0.89	0.77	46
	447	0.00	0.00	0.00	69
	448	0.00	0.00	0.00	7
	449	0.00	0.00	0.00	3
	450	0.00	0.00	0.00	52
	451	0.02	0.06	0.03	16
	452	1.00	0.41	0.58	17
	453	0.00	0.00	0.00	13
	454	0.25	0.27	0.26	11
	455	0.08	0.08	0.08	12
	456	0.00	0.00	0.00	6
	457	0.00	0.00	0.00	18
	458	0.00	0.00	0.00	15
	459	0.67	0.07	0.13	28
	460	0.00	0.00	0.00	18
	461	0.00	0.00	0.00	10
	462	0.00	0.00	0.00	24
	463	0.00	0.00	0.00	18
	464	0.00	0.00	0.00	39
	465	0.08	0.09	0.08	11
	466	0.00	0.00	0.00	35
	467	0.10	0.14	0.12	21
	468	0.00	0.00	0.00	37
	469	0.00	0.00	0.00	5
	470	0.00	0.00	0.00	8
	471	0.75	0.24	0.37	37
	472	0.00	0.00	0.00	47
	473	0.00	0.00	0.00	14
	474	0.83	0.43	0.57	23
	475	0.00	0.00	0.00	66
	476	0.50	0.33	0.40	3
	477	0.38	0.42	0.40	19
	478	0.00	0.00	0.00	1
	479	0.00	0.00	0.00	23
	480	0.00	0.00	0.00	60
	481	0.00	0.00	0.00	26
	482	0.00	0.00	0.00	4
	483	0.00	0.00	0.00	8
	484	0.56	0.22	0.31	23
	485	0.31	0.22	0.26	18
	486	0.70	0.58	0.64	12
	487	0.00	0.00	0.00	29
	488	0.00	0.00	0.00	1
	489	0.50	0.17	0.25	6
	490	0.00	0.00	0.00	7
	491	0.00	0.00	0.00	3
	492	0.30	0.30	0.30	10
	493	0.18	0.16	0.17	19
	494	0.00	0.00	0.00	7
	495	0.40	0.25	0.31	8
	496	0.29	0.11	0.16	18
	497	0.00	0.00	0.00	72
	498	0.14	0.25	0.18	8
	499	0.60	0.28	0.38	32
	micro avg	0.52	0.26	0.35	37472
	macro avg	0.28	0.20	0.21	37472
	weighted avg	0.46	0.26	0.31	37472
	samples avg	0.34	0.26	0.27	37472

Observations

```
In [22]: # Pretty table
from prettytable import PrettyTable
x=PrettyTable(["model","vectoriser","micro_f1","accuracy","precision","recall","hamming_loss"])

x.add_row(["LR without hypertune","ngram=(1,4)","0.4489","0.174","0.583","0.3649","0.0033"])
x.add_row(["LR with hypertune","ngram=(1,4)","0.4488","0.1743","0.5828","0.3650","0.0033"])
x.add_row(["SVM without hypertune","ngram=(1,4)","0.3511","0.1303","0.5228","0.2035","0.0036"])

print("NOTE: These results are from only 100k datapints (80k train and 20k test) and ony 100k features(dimention)")
print("***100,\n")
print("***30,"pretty table",***30)
print(x)
```

NOTE: These results are from only 100k datapints (80k train and 20k test) and ony 100k features(dim)

\*\*\*\*\*

\*\*\*\*\* pretty table \*\*\*\*\*

model	vectoriser	micro_f1	accuracy	precision	recall	hamming_loss
LR without hypertune	ngram=(1,4)	0.4489	0.174	0.583	0.3649	0.0033
LR with hypertune	ngram=(1,4)	0.4488	0.1743	0.5828	0.3650	0.0033
SVM without hypertune	ngram=(1,4)	0.3511	0.1303	0.5228	0.2035	0.0036